San Cris · Asistente pericial de seguros automotor

Sistema experto basado en grafos de estado (LangGraph), RAG híbrido y agentes ReAct

Equipo & Comisión

UTN FRRO · Comisión 502

Anmuth, Cabanellas, Casado, Escobar, Maragliano

Componentes Clave Del Archivo Técnico

Orquestación con **LangGraph**, inferencia en **Groq** (gpt-oss-120b y visión qwen3.8-27b), base vectorial **ChromaDB** y almacenamiento transaccional **SQLite**.

El problema: ambigüedad contractual y datos heterogéneos

Complejidad del dominio

- Pólizas con cláusulas generales, exclusiones específicas y alcances cruzados basados en un manual de 27 páginas.
- Asimetría de información: el asegurado desconoce su cobertura exacta y los plazos administrativos.

Integración y restricciones técnicas

- La consulta requiere integrar simultáneamente tres fuentes: lenguaje natural no estructurado (relato y fotos), base documental normativa (PDF) y base de datos relacional (estado de póliza, vigencia y pagos).
- Es fundamental no delegar la validez jurídica ni las operaciones matemáticas a la inferencia probabilística del modelo.

Arquitectura: separación de flujos en LangGraph

El sistema utiliza un diagrama de estados con responsabilidades separadas:

CÓDIGO DETERMINÍSTICO
Extracción regex de patentes/DNI, consultas SQL, validaciones administrativas y cálculo de franquicias.

RECUPERACIÓN RAG
Búsqueda híbrida en manual indexado.

MODELOS DE LENGUAJE
Clasificación de intención, descripción visual de daños y redacción de fundamentos.

Los dos caminos del grafo

Flujo determinístico de siniestros — Camino fijo y auditado

PASO 1 **Análisis visual** → PASO 2 **Consulta de póliza** → PASO 3 **Recuperación de cláusulas** → PASO 4 **Dictamen** → PASO 5 **Controles administrativos** → PASO 6 **Persistencia**

Flujo dinámico de consultas
Subagente ReAct con seis herramientas de lectura.

Consultas dinámicas: agente ReAct de solo lectura

DECISIONES DE DISEÑO

Solo lectura

El agente no posee la herramienta `registrar_siniestro` para evitar que el modelo persista registros salteando controles.

Aritmética externa

El cálculo de franquicias lo realiza el código; el modelo no opera matemáticamente.

Trazabilidad

Visualización completa de herramientas invocadas, parámetros y similitud de fragmentos.

HERRAMIENTAS EXPUESTAS AL AGENTE

Herramienta	Función / Componente
`consultar_datos_poliza`	Consulta de póliza por patente
`consultar_polizas_por_dni`	Búsqueda de pólizas por DNI de titular
`consultar_clausulas_poliza`	Retrieval sobre condiciones y exclusiones
`consultar_estado_reclamo`	Ficha y estado de un reclamo por número
`listar_reclamos`	Historial de reclamos por patente o DNI
`calcular_pago_cliente`	Cálculo determinístico de franquicia y montos

Estrategia de recuperación: chunking jerárquico y búsqueda híbrida

Procesamiento y chunking

Exclusión de páginas de índice para evitar dispersión léxica.

Se aplica **chunking estructural por ítems normativos** propagando el encabezado de sección (ej. *Exclusiones a la cobertura para Robo o Hurto → Ítem 5: GNC*) para evitar descontextualizar cláusulas específicas.

Mecanismo de retrieval

Búsqueda híbrida combinando `BM25` (léxica precisa para términos como *granizo* o *GNC*) y `multilingual-e5-base` (semántica).

Ambas búsquedas son fusionadas mediante **`EnsembleRetriever`** utilizando una distribución de pesos equilibrada `(pesos 0.5 / 0.5)`.

Manejo de atributos del vehículo

Si la base relacional indica que el rodado tiene **GNC**, se dispara una segunda búsqueda focalizada en exclusiones específicas para inyectarlas directamente en el contexto de inferencia.

Demostración del sistema y trazabilidad

Casos de prueba a recorrer durante la demostración en vivo

01

Consulta con memoria y cálculo

Consulta de póliza, pregunta de seguimiento y cálculo de franquicia.

02

Denuncia de siniestro con control de vigencia

Póliza vencida donde el modelo sugiere cobertura pero el control del sistema fuerza el rechazo.

03

Análisis multimodal

Siniestro con foto discordante (relato de granizo con imagen de choque frontal) derivada a peritaje.

Trazabilidad y Métricas en Tiempo Real

Monitoreo en vivo de consumo de tokens, latencia por nodo y costo acumulado durante la ejecución de los tres casos de prueba.

Resiliencia y telemetría: fallback de modelos y costos

Consumo Promedio	Costo Estimado	Límite de Contexto
~9.000	~US$ 0,002	12 Mensajes
TOKENS / DENUNCIA	POR DENUNCIA PROCESADA	COMPACTACIÓN + RESUMEN

Disyuntor y conmutación por cuota

Arquitectura de Respaldo: Modelo principal `gpt-oss-120b` con conmutación automática a `gpt-oss-20b` ante fallos o agotamiento de cuota.

Memoria de Bloqueo: Implementa retención de estado para evitar reintentos fallidos e innecesarios durante el tiempo de espera informado por la API cuando un modelo agota su límite diario.

Garante de Disponibilidad

Previene bloqueos en la cascada de procesamiento y optimiza la continuidad operativa ante degradaciones del proveedor.

Procesamiento multimodal desacoplado

Visión Acotada: Empleo de `qwen3.8-27b` limitado estrictamente a la descripción técnica de daños (`max_tokens=400`).

Aislamiento de Análisis: La comparación entre foto y relato se ejecuta mediante una llamada atómica independiente, evitando la dilución de contexto en prompts extensos.

Gestión de Memoria: La compactación de historial aplica `RemoveMessage` junto con un resumen consolidado al superar el umbral de doce mensajes.

Evaluación empírica: límites del RAG y del modelo de lenguaje

Falla en recuperación (Caso vehículo con GNC)

Síntoma

Robo cubierto incorrectamente.

Diagnóstico

Falla de recuperación, no de razonamiento; el usuario no escribe `"tengo GNC"` al denunciar un robo, por lo que la cláusula nunca ingresaba al prompt.

Solución

Inyección contextual guiada por el estado del vehículo en la base de datos.

Variabilidad estocástica (Caso Chevrolet Cruze todo riesgo)

Síntoma

El robo salió cubierto 1 de cada 5 corridas con `temperature=0`.

Diagnóstico

Con la regla presente en contexto, el modelo priorizó la jerarquía de "todo riesgo" por sobre la exclusión.

Resolución Técnica

Documentar y asumir la no determinabilidad inherente a los modelos en casos de alta ambigüedad semántica.

Asignación de responsabilidades: código vs modelo

Dimensión	Lógica determinística (código / SQL)	Lógica generativa (LLM / visión)
Pólizas y pagos	Consulta relacional de estado y cuota al día	Comprensión de la consulta del usuario
Vigencia temporal	Comparación estricta de fecha siniestro vs póliza	Normalización de expresiones temporales (*"ayer"*)
Plazo de denuncia	Rechazo administrativo si transcurren > 72 h	Extracción del relato del hecho
Deduplicación	Cruce por patente, fecha y familia de daño	Clasificación semántica del tipo de daño
Dictamen final	Ficha inmutable y persistencia relacional	Redacción del fundamento y pasos a seguir

Conclusiones y evolución del sistema

Validación del sistema

- Batería final de 25 casos de prueba automatizados con verificación de estado y trazas.
- Despliegue reproducible en un solo paso mediante `iniciar.py` con dependencias congeladas.

Limitaciones identificadas

- Falta de contemplación de fuerza mayor en denuncias tardías.
- Ambigüedad del manual frente a granizo o cristales en vehículos adaptados a GNC.

Líneas futuras de desarrollo

- Incorporación de herramientas para solicitud y despacho de auxilio mecánico.
- Extensión de exclusiones a gas licuado (GLP) y transporte de pasajeros.